GSM8K · Man: I − E
Jumlah kata

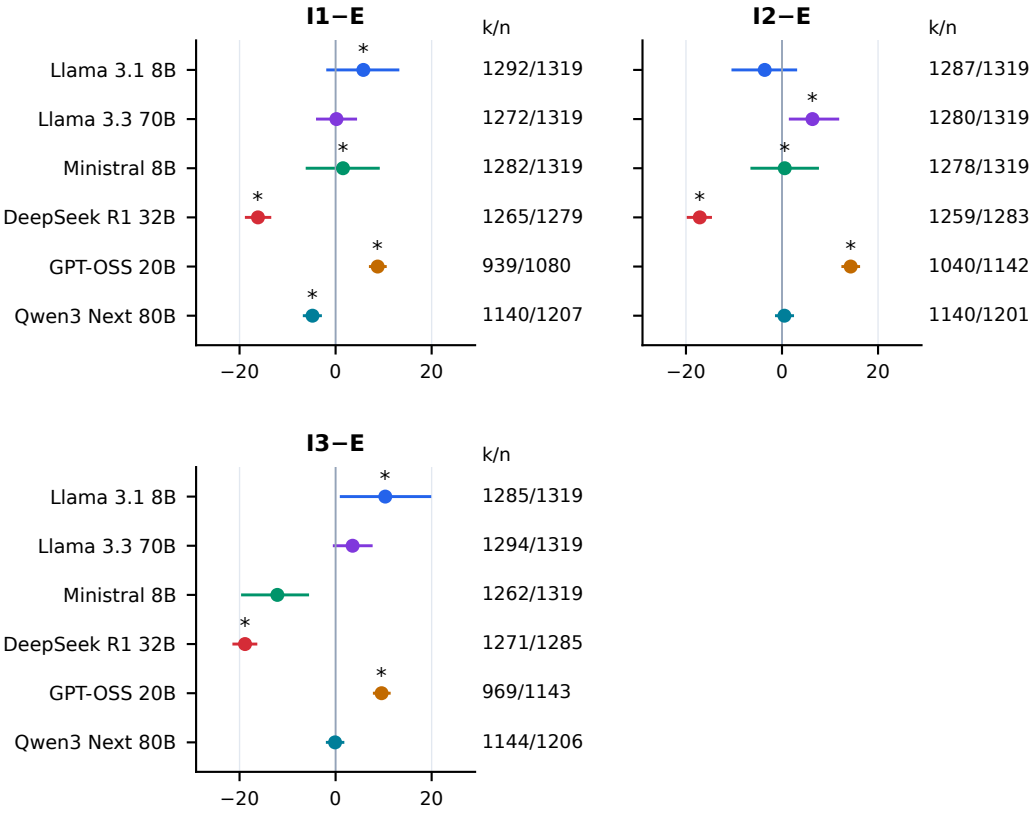

Titik: selisih rata-rata · garis: CI bootstrap 95% rata-rata

* Wilcoxon–Holm p<0,05 (bukan uji rata-rata) · CI jika n≥2

k/n: berubah/tersedia · segitiga: n<20 · TP/ND: tak berubah/tak tersedia

Positif: kiri lebih tinggi · I1–I3: variasi warmup · Kandidat